GO3-XAI01-04 / M5 · E

六种视觉归因方法：质量、稳定性与取舍

汇总正式 DCU 评测证据，补齐真实同图案例与固定演示

IG | Grad-CAM | Occlusion | RISE | KernelSHAP | LIME-8000

M5 展示工作稿 · 案例 215 / 3803 / 7612 已选定 · 18 张正式 PNG 预览已核验

2026-10-28 | 统计基线：feat/kernelshap-analysis @ 2989537

STUDY DESIGN

同一评测契约覆盖 36 个模型 × 数据 × 方法单元

每个数据集 / 模型组合使用 460 张 eval 图；汇总主分析只看各模型命中样本。

方法	CNN	数据集	每单元
6 种	3 个	2 个	460 张

固定图像与真值 target

eval split · 同图配对

→

六种归因图

同一模型权重 · 各自配置

→

三类证据

raw MoRF · 噪声稳定性 · 记录时间

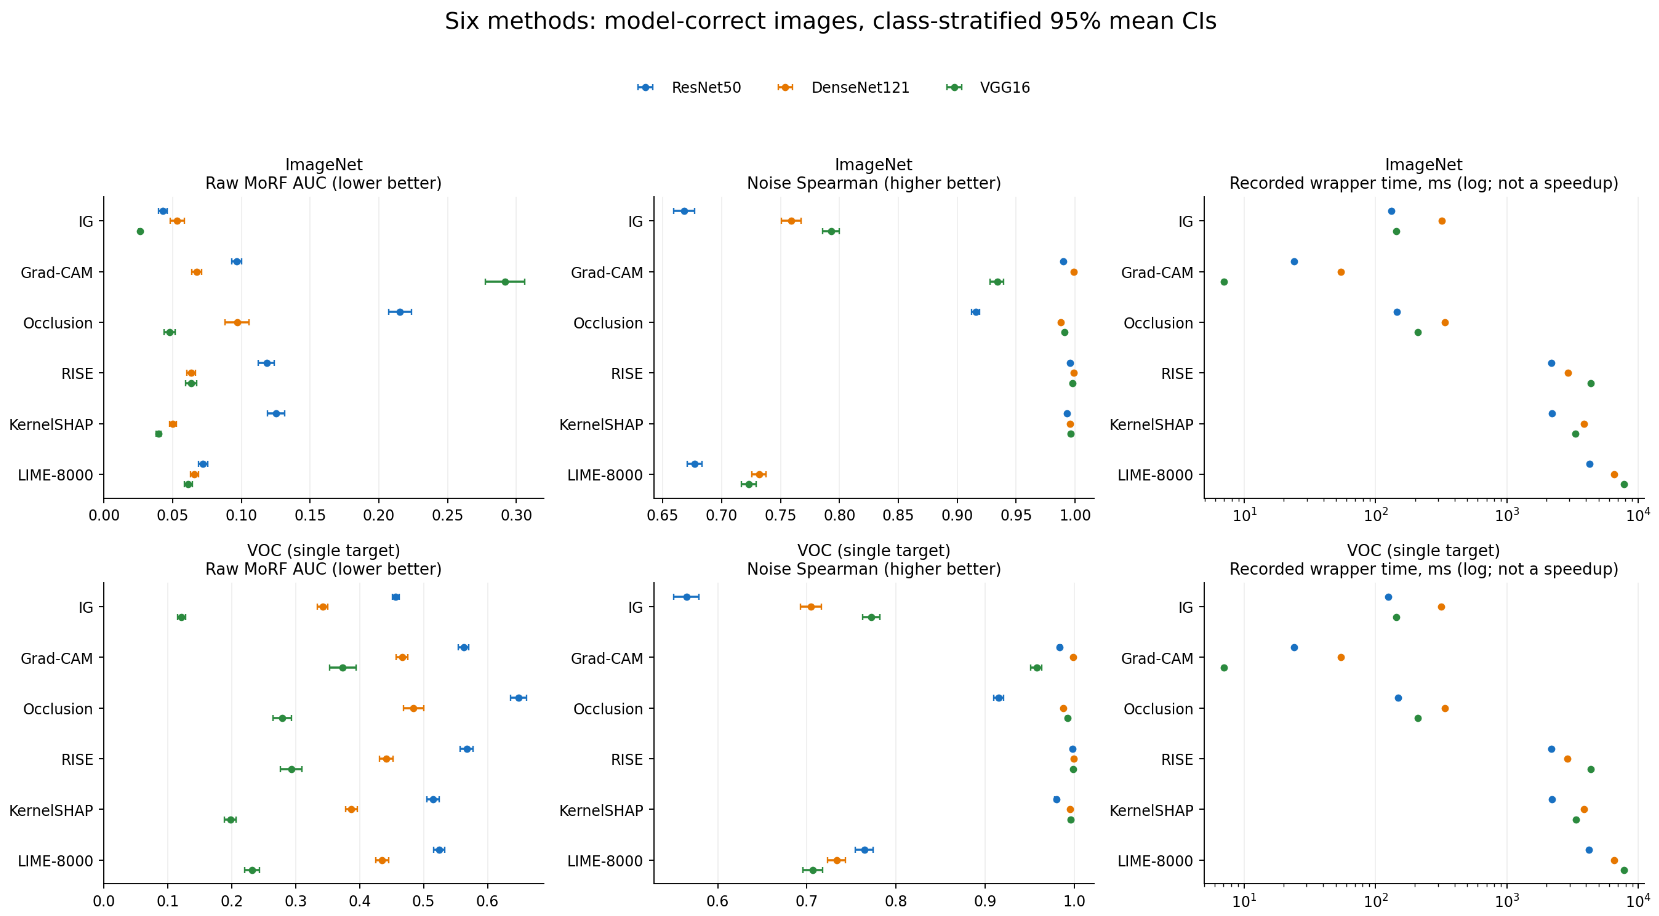
口径边界

ImageNet 与 VOC 不横向比 raw AUC；VOC 的命中是冻结单目标的 sigmoid argmax，不是多标签 exact match 或 mAP。跨模型比较使用共同命中组。

RQ1 + RQ2

忠实性与稳定性并不总由同一种方法领先

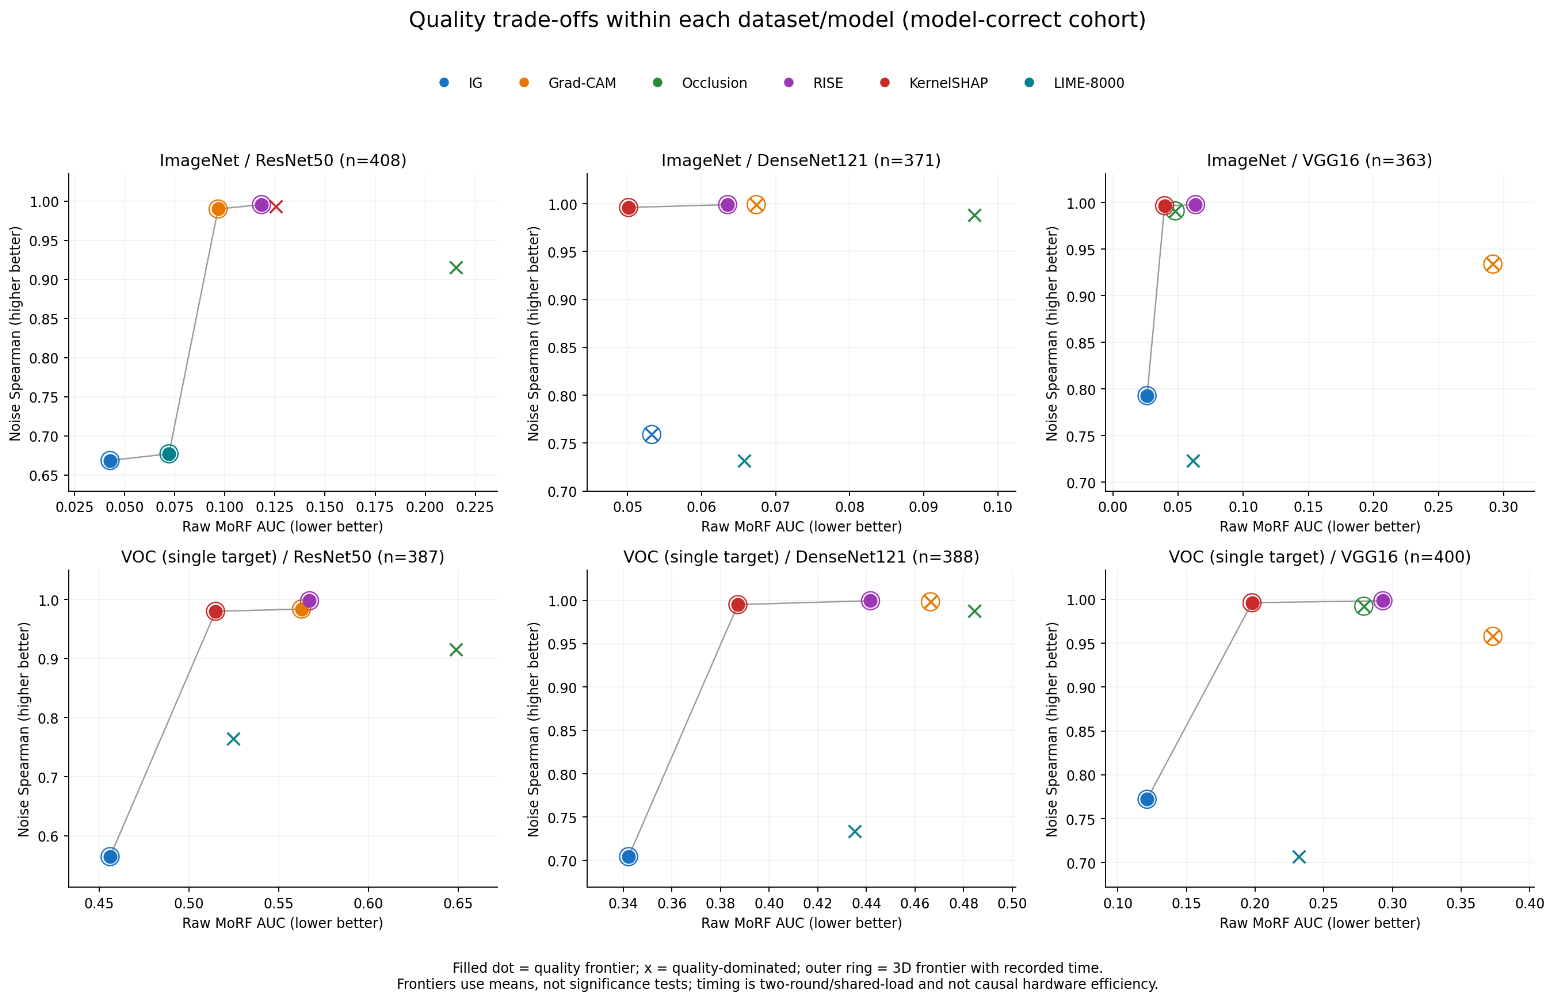
均值误差线为类别分层 bootstrap 95% 边际 CI；耗时是归因 wrapper 记录值。



读图：IG 在 6 组中的 5 组 AUC 均值最低；RISE 在 6 组中平均噪声稳定性最高。

质量前沿随数据集和模型改变

横轴 raw MoRF AUC 越低越好；纵轴噪声 Spearman 越高越稳定。



没有全局冠军

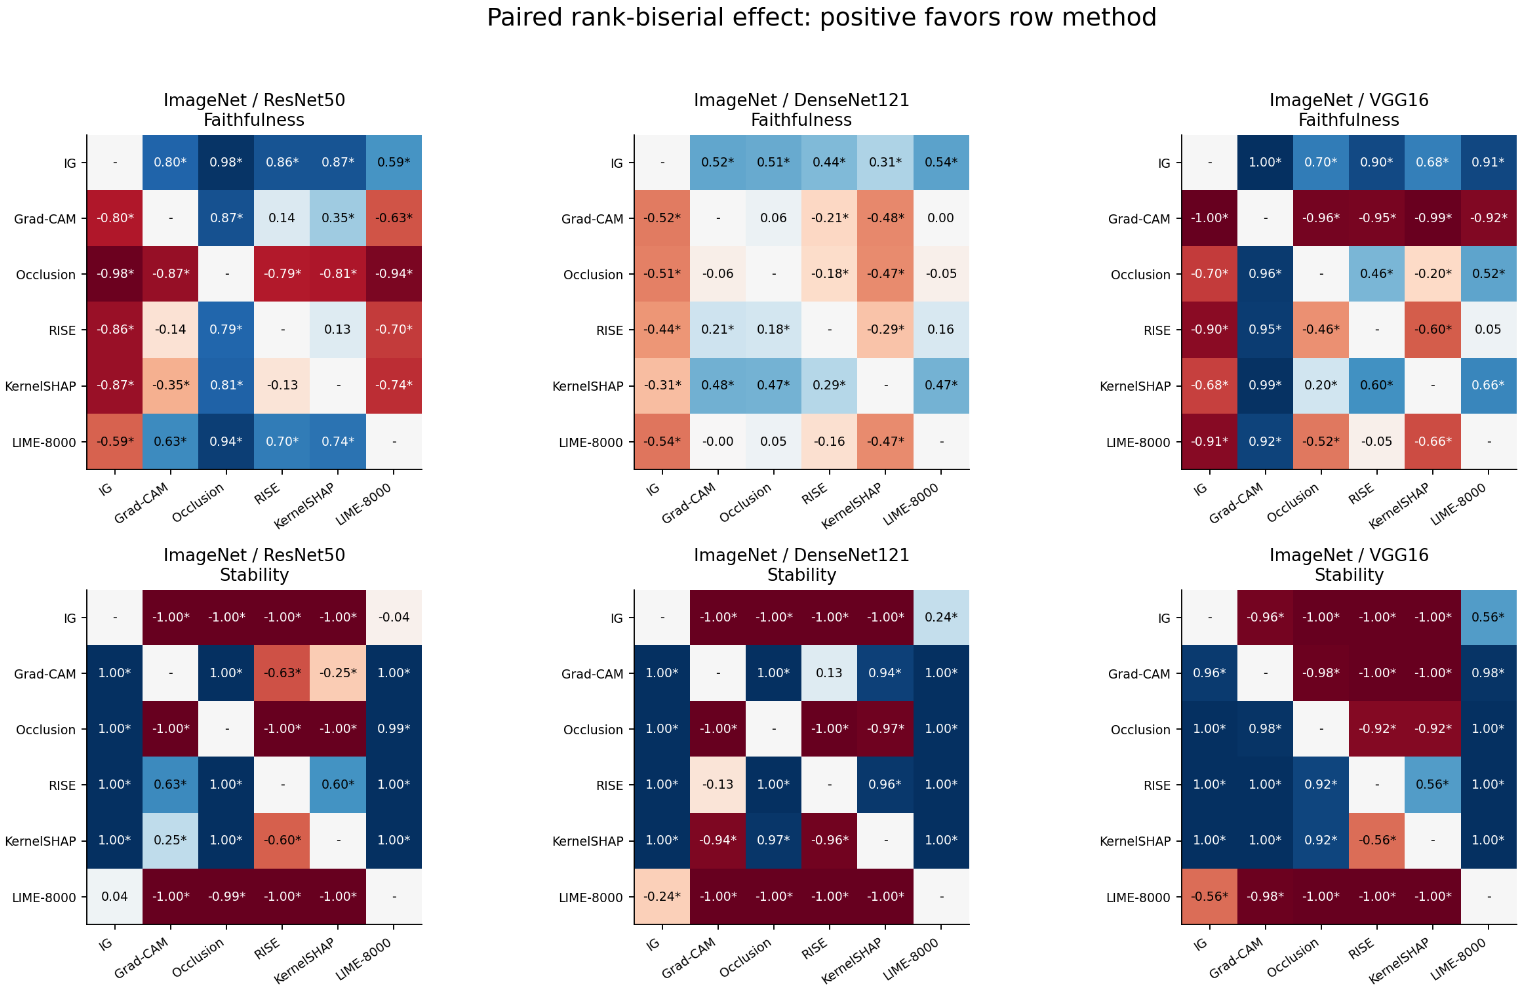
各单元质量前沿包含 2–4 种方法。要按模型、数据和目标选择。

计时只作背景

图中 3D 前沿使用本批次 wrapper ms；共享负载和不同实现路径限制了速度结论。

ImageNet：配对秩效应支持取舍，不等于均值差

热图数字是配对 rank-biserial effect；正值偏向行方法。星号为 Holm 校正秩检验，不是均值检验。



怎么读

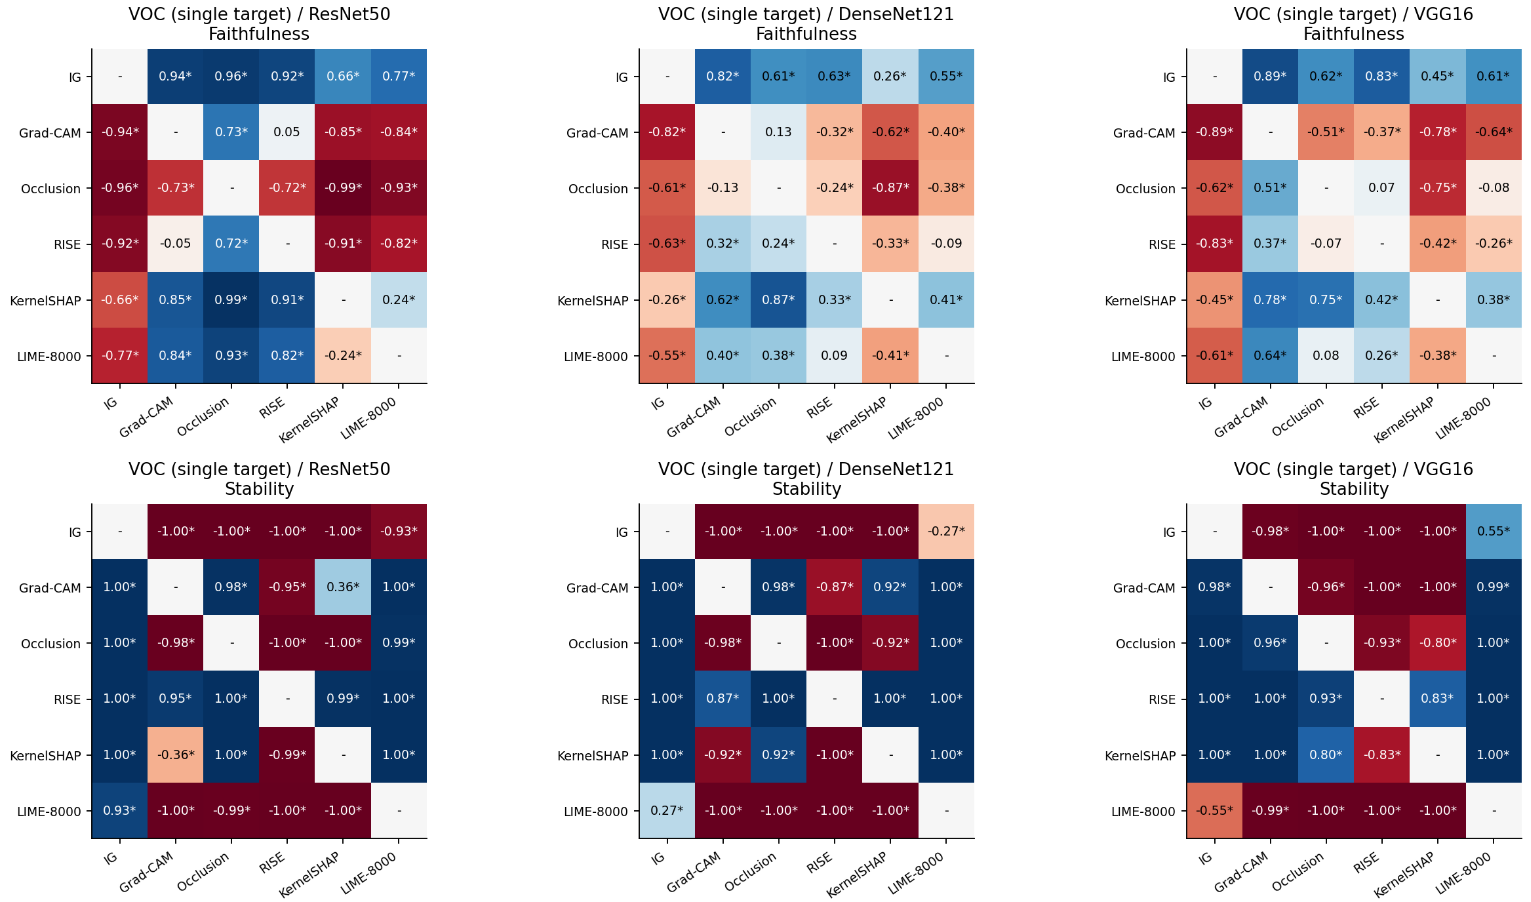
蓝色正值：行方法占优
红色负值：列方法占优
数值是秩效应，不是均值差

本页要点

IG 的 AUC 均值在 ResNet50 / VGG16 更低；DenseNet121 的均值差 CI 跨零。

VOC：单目标协议下，质量结论仍依赖模型

VOC 结论仅适用于该冻结 target 协议；不外推为 VOC 多标签 mAP。



* Two-sided Wilcoxon Holm $p < .05$; one 180-comparison quality family across both metrics and six strata.

怎么读

蓝色正值：行方法占优
红色负值：列方法占优
数值是秩效应，不是均值差

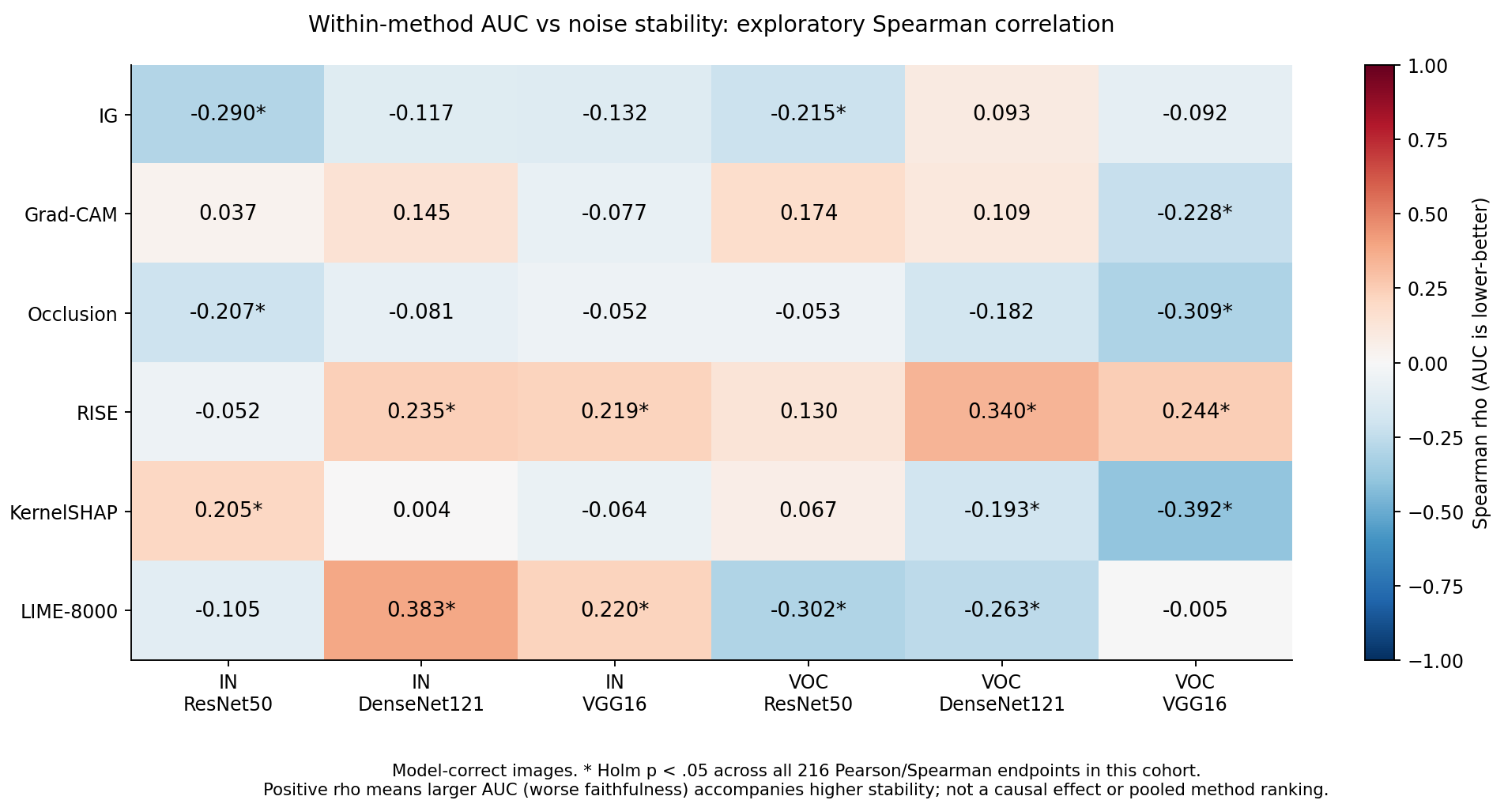
本页要点

IG 在三种模型的 AUC 均值均最低，但质量与稳定性仍要分开报告。

RQ3 · EXPLORATORY

稳定性与忠实性之间没有简单单调关系

Spearman 相关在每个方法 / 模型 / 数据集内计算；它不是因果分析。



显著相关不等于方法排名

相关方向在方法间不一致。AUC 越大代表忠实性越差；正相关表示较差 AUC 伴随更高稳定性。

统计边界

216 个 Pearson / Spearman 端点一起做 Holm 校正。该页用于描述关系，不支持机制或因果解释。

LIME：局部线性近似，正式比较预算为 8,000 个扰动样本

实现固定 Quickshift 分割、Bernoulli superpixel masks、核加权 Ridge，再把系数投影回像素。

样本与批量
8,000 / 32

分割
Quickshift · seed 42

扰动核
exponential · width 0.25

回归
Ridge α=1 · all superpixels

VOC / ResNet50 · model-correct n = 387

LIME-8000 raw AUC	噪声 Spearman	wrapper time
0.52481	0.76451	4,218.50 ms

该固定预算不是收敛证明；同单元 IG 的平均 AUC 更低，RISE 的平均稳定性更高。计时不能视作跨 GPU 效率排名。

CASE GALLERY · MAPS VERIFIED

三张 eval 展示案例：绑定真值、指标与六方法正式图

按可复现规则事后选图（非实验前预注册）；地图文件与来源哈希已核验。

image_id 215 · cat

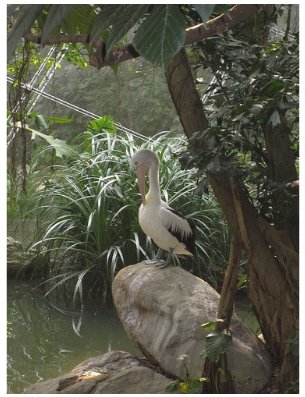


四指标名次画像匹配中位数（L1=0）
confidence 0.9662

最低 AUC：IG 0.450
最高稳定性：RISE 1.000

六方法正式图已核验
展示案例已确定

image_id 3803 · bird



名次差平方和 70，与 4675 并列
按较小 ID 选 3803 · conf 0.8687

最低 AUC：IG 0.611
最高稳定性：RISE 1.000

六方法正式图已核验
展示案例已确定

image_id 7612 · dog



387 张命中样本中置信度最低
0.5393 · 仍命中真值（非误分类）

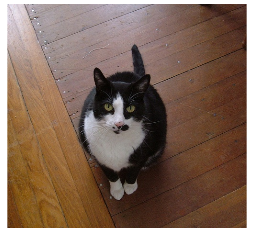
最低 AUC：LIME 0.202
最高稳定性：RISE 0.999

六方法正式图已核验
展示案例已确定

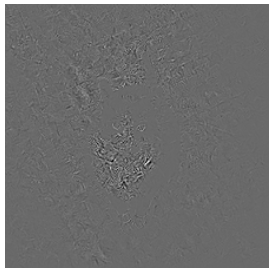
SAME INPUT · OFFICIAL MAP PREVIEWS

同一张 eval 图像的六方法归因预览

VOC / ResNet50 · image_id 215 · 真值 cat (7) · confidence 0.9662 · 按中位名次画像规则选中（L1=0）



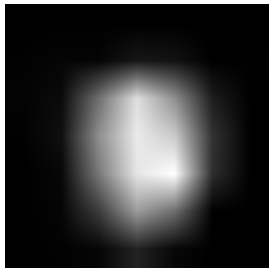
IG



raw MoRF AUC 0.450
noise Spearman 0.600
记录耗时 126.8 ms

PNG SHA 20afbb394c1e…
NPY SHA 91c129b468a1…

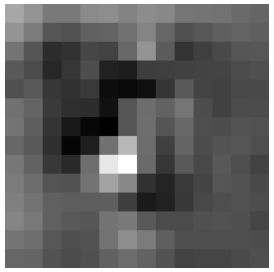
Grad-CAM



raw MoRF AUC 0.610
noise Spearman 0.998
记录耗时 24.4 ms

PNG SHA a74467edc833…
NPY SHA 56f9fb5bb5d0…

Occlusion



raw MoRF AUC 0.861
noise Spearman 0.846
记录耗时 148.4 ms

PNG SHA 299768c94752…
NPY SHA 83eeca554762…

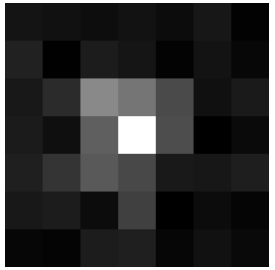
RISE



raw MoRF AUC 0.618
noise Spearman 1.000
记录耗时 2179.3 ms

PNG SHA b874a64e1a84…
NPY SHA 83a2d6e6f0b2…

KernelSHAP



raw MoRF AUC 0.559
noise Spearman 0.992
记录耗时 2166.2 ms

PNG SHA 3161f305ad4f…
NPY SHA 52cebc5ce45f…

LIME-8000



raw MoRF AUC 0.563
noise Spearman 0.725
记录耗时 4212.6 ms

PNG SHA 4102085d8ed8…
NPY SHA cf21ef209907…

PNG 为归档提供的灰度预览；不按灰度强度跨方法排序。定量结果来自 float32 NPY；完整 SHA、sidecar 与配置索引见固定 Demo。

CLOSE

答辩结论：按目标选方法，展示图必须带来源

展示案例已按规则选定；独立环境演练和交付回执仍待完成。

01 IG 的平均 raw MoRF AUC 在六组中的五组最低；ImageNet / DenseNet121 是例外，均值差 CI 跨零。

02 RISE 的平均噪声稳定性在六组均最高；稳定不等于忠实性最佳。

03 质量前沿随数据与模型改变；没有跨指标、跨单元的统一冠军。

最终交付还剩两项

本地稿已确定 215 / 3803 / 7612 及其选择规则；Issue #22 待同步。之后完成独立环境演练，记录原图和每例 6/6 地图加载。Demo 只含正式 PNG 预览与来源哈希，不含完整 NPY、数据集或权重。